Nouveaux paradigmes de bases de données

Wissem Inoubli - Nejat Arinik
IUT de Lens BUT Info S5 2026 2027

TP 3 : Les bases de données orientées graphes avec neo4j

1 Insertion et manipulation de données avec cypher-shell

Dans un premier temps, nous allons effectuer quelques manipulations pour nous familiariser avec *Cypher*, le langage de manipulation et d'interrogation des bases de données Neo4j. Donnez les commandes *Cypher* qui permettent de réaliser les opérations suivantes:

1. Utilisez les deux opérateurs `MERGE` et `CREATE`, ainsi que les deux modes d'insertion (élément par élément et par lot), pour :
   - créer les noeuds ayant les caractéristiques spécifiées dans le tableau 1 ;
   - créer les relations ayant les caractéristiques spécifiées dans le tableau 2.
2. Afficher la liste des noeuds créés (de chaque type) ;
3. Calculer le nombre de noeuds créés (de chaque type) ;
4. Afficher toutes les personnes dont l'âge est supérieur à 20 ;
5. Afficher les noms de toutes les personnes, triés par ordre croissant selon l'âge ;
6. Afficher le nombre de personnes dont l'âge est supérieur à 20 ;
7. Afficher le nombre de personnes pour chaque âge ;
8. Afficher l'âge moyen de toutes les personnes.

Table 1: noeuds à insérer

ID	Label	Attribut 1	attribut 2
1	Personne	Nom:Bob	age:33
2	Personne	Nom: Alice	age:18
3	Personne	Nom: Ben	age:25
4	Véhicule	Type:voiture	modèle:clio
5	Véhicule	Type:moto	modèle:R1
6	Véhicule	Type:voiture	modèle:A4

Table 2: Relations à insérer

De	Label	vers	attributs
1	Posséder	4	Depuis : 2014
2	Posséder	5	Depuis : 2007
3	Posséder	6	Depuis : 2010
1	Conduire	4	
2	Conduire	5	
3	Conduire	6	
2	Conduire	4	

2 Insertion et manipulation de données avec *py2neo*

1. En utilisant la bibliothèque py2neo, supprimez les données de l'exercice précédent et réinsérez les mêmes données à l'aide d'un script Python.
2. Exécutez les mêmes requêtes que dans l'exercice précédent (questions 2 à 8) avec l'API Neo4j.

3 Manipulation de données (tweets) avec *py2neo*

Étant donné le modèle de données suivant et les fichiers CSV partagés sur Moodle.

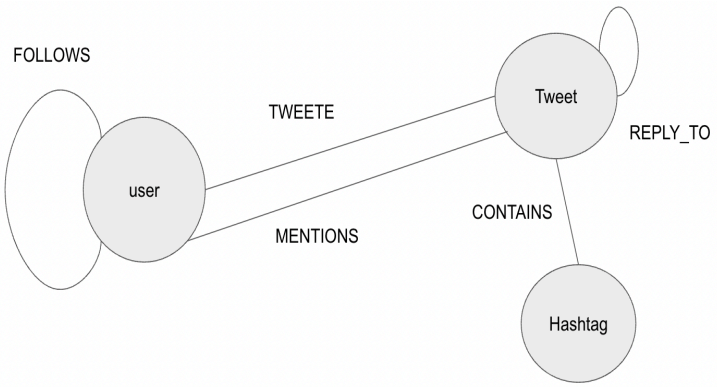


Figure 1: Modèle de données

Détails sur les fichiers CSV :

- le fichier *tw_user.csv* : les utilisateurs ;
- le fichier *tweet.csv* : les tweets des utilisateurs (le séparateur ici est "<") ;
- le fichier *tweet_hashtag.csv* : les hashtags dans les tweets et les relations `CONTAINS` entre un hashtag et un tweet ;
- le fichier *tw_user_follow.csv* : les relations de type `FOLLOWS` ;
- le fichier *tweet_mention.csv* : les relations de type `MENTIONS` ;
- le fichier *tweet_reply.csv* : les relations de type `REPLY_TO`.

En utilisant la bibliothèque py2neo en Python, créez une base de données Neo4j (`twitter`) et implémentez un script ou notebook Python permettant de charger les données de ces fichiers sous forme d'une base de données orientée graphe. Ajoutez les contraintes d'intégrité nécessaires pour éviter les doublons.

En utilisant py2neo et Cypher, répondez aux requêtes suivantes :

1. Donner le nombre d'utilisateurs ;
2. Donner le nombre de tweets ;
3. Donner le nombre d'hashtags ;
4. Donner le nombre de tweets contenant le hashtag "actualite" ;
5. Donner le nombre d'utilisateurs différents ayant publié un tweet contenant le hashtag "valls" ;

6. Donner les tweets qui sont des réponses à un autre tweet ;
7. Donner le nombre de followers de "Spinomade" ;
8. Donner le nombre d'utilisateurs suivis par "Spinomade" ;
9. Donner les noms des followers de "Spinomade".
10. Calculer, pour chaque utilisateur : le nombre de followers ; le nombre de statuts ; le nombre de hashtags ; le nombre de personnes suivies.
11. Calculer le nombre moyen de statuts par utilisateur et le nombre moyen de followers par utilisateur.

4 Manipulation de données avec *py2neo*

Voici le schéma de données :

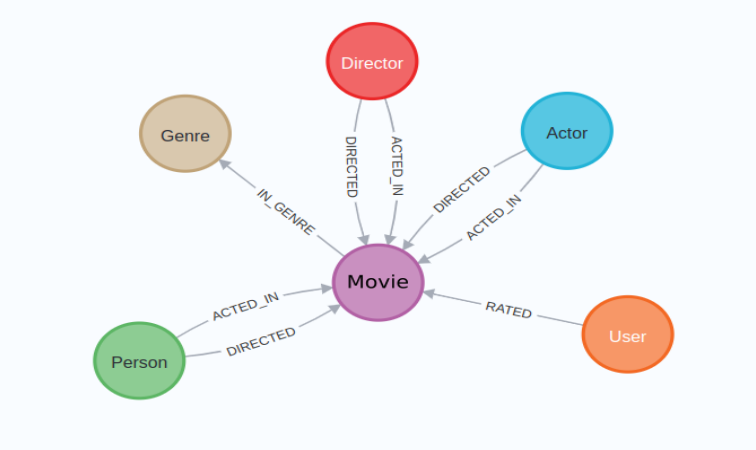


Figure 2: Modèle de données

1. En utilisant les données partagées sur Moodle (données de l'exercice 5), insérez les données dans la base Neo4j avec un script Python, en respectant le schéma de données fourni.
2. Retourner les 10 premiers films du label `Movie`.
3. Quels sont les 5 films les mieux notés ?
4. Quels sont les acteurs du film le mieux noté ?
5. Quels sont les acteurs des films dont la note est supérieure à 9 ?
6. Lister les films ayant au moins 2 réalisateurs, ainsi que les noms des personnes ayant donné leur avis sur ces films.
7. Lister tous les films de 'Tom Hanks'.
8. Lister le nombre de co-acteurs de 'Tom Hanks'.
9. Lister tous les co-acteurs de 'Tom Hanks'.
10. Trouver les "co-co-acteurs" de 'Tom Hanks', c'est-à-dire les acteurs ayant joué avec un co-acteur de 'Tom Hanks', mais jamais directement avec 'Tom Hanks' dans un même film.
11. Comme dans la question précédente, trouver les "co-co-acteurs" de 'Tom Hanks'. Cette fois-ci, indiquer dans la sortie le nombre d'occurrences (fréquence) de chaque "co-co-acteur".

12. Quels sont les co-acteurs de 'Tom Hanks' qui ont également joué dans un film avec 'Tom Cruise' ? Visualiser les chemins possibles entre 'Tom Hanks' et 'Tom Cruise'.

5 Application : moteur de recommandation de métiers

ESCO (European Skills, Competences, Qualifications, and Occupations) est une classification européenne des compétences, des qualifications, des professions et des emplois. Il s'agit d'un système de classification développé par la Commission européenne pour aider à harmoniser et à comparer les informations sur l'emploi et l'éducation au sein de l'Union européenne. ESCO vise à faciliter la correspondance entre les qualifications, les compétences et les emplois, ce qui est particulièrement important dans un contexte européen où les systèmes éducatifs et les marchés du travail varient d'un pays à l'autre. Grâce à ESCO, il est plus facile de comprendre comment une qualification ou une compétence obtenue dans un pays européen correspond à un emploi ou à une qualification dans un autre pays de l'UE.

1. Compétences et compétences : ESCO répertorie une vaste gamme de compétences et de compétences professionnelles qui peuvent être associées à différents emplois. Il offre des descriptions détaillées de ces compétences, y compris leurs niveaux de compétence et leur pertinence pour différents domaines professionnels.
2. Qualifications : ESCO répertorie les qualifications éducatives et professionnelles, telles que les diplômes, les certificats et les titres de compétence, et les associe à des niveaux de qualification. Cela facilite la comparaison des qualifications entre les pays de l'UE.
3. Professions et emplois : ESCO contient des informations sur les professions et les emplois, y compris leurs descriptions, leurs tâches principales, leurs compétences requises et d'autres informations pertinentes. Il utilise un système de classification pour organiser ces professions et emplois.

Le but principal de cette application est de créer un système de recommandation innovant qui peut suggérer une liste de métiers appropriés en fonction des compétences fournies en entrée. En outre, cette application offre également des fonctionnalités permettant d'explorer des opportunités de transition vers d'autres métiers.

En détail, ce que vous allez développer :

1. Chargement des données dans la base Neo4j : les données sont publiées sur Moodle sous forme d'un fichier CSV, avec les colonnes suivantes : métier, appellations (séparées par des virgules), compétences et connaissances requises, compétences et connaissances optionnelles (également séparées par des virgules).
2. Fiche métier : cette fonctionnalité permet aux utilisateurs d'afficher un métier donné avec toutes les compétences et connaissances associées, ainsi que ses autres appellations.
3. Compétence/connaissance : Cette fonctionnalité permet de voir une compétence ou/et connaissance donnée où elle est requise ou facultative et pour quels métiers.
4. Similarité entre compétences : cette fonction permet de calculer la similarité entre deux compétences données, en se basant sur leur co-occurrence dans les mêmes métiers. Le calcul de similarité doit également prendre en compte le caractère obligatoire ou facultatif de chaque compétence dans ces métiers.
5. Similarité entre métiers : Cette fonction permet de calculer la similarité entre deux métiers donnés, en se basant sur lintersection de leurs compétences, quelles soient obligatoires ou supplémentaires.

6. Recommandation métier : cette fonctionnalité permet de retourner une liste des métiers à recommander à l'utilisateur selon ses compétences données.

7. Mobilité professionnelle : en plus de fournir des recommandations de métiers, l'application propose également une fonctionnalité de mobilité professionnelle. Elle suggère des métiers qui pourraient représenter une transition logique à partir des compétences et du métier actuel de l'utilisateur. Cette fonctionnalité prend en entrée un métier actuel (avec l'ensemble des compétences du candidat, pas seulement celles associées à son métier) et un métier cible ; elle retourne un pourcentage de correspondance entre les deux, ainsi que la liste des compétences manquantes pour atteindre ce métier cible.

Pour les mesures de similarités, vous pouvez utiliser la similarité de Jaccard qui consiste à mesurer la similarité entre deux ensembles. Elle mesure la similitude entre deux ensembles en calculant le rapport de la taille de leur intersection sur la taille de leur union. La formule de la similarité de Jaccard est la suivante : Similarité de Jaccard = (Taille de l'intersection des ensembles) / (Taille de l'union des ensembles), cela peut être exprimé comme : $J(A, B) = |A \cap B|/|A \cup B|$
où :
J(A, B) représente la similarité de Jaccard entre les ensembles A et B.
$|A \cap B|$ représente la taille de l'intersection des ensembles A et B.
$|A \cup B|$ représente la taille de l'union des ensembles A et B.

6 Application : moteur de recommandation de métiers avec la base de données MongoDB

Dans cette application, vous allez reprendre l'application précédente en utilisant cette fois la base de données MongoDB. Vous comparerez ensuite les deux solutions en termes de temps de réponse.